# Нейросетевые подходы к разработке рекомендаций по повышению продаж в товарных корзинах

Neural network to up-sell recommendations on shopping carts

**Автор**: Ляпин Данила Александрович
**Научный руководитель**: Хажгериев Мурат Анзорович

НИУ ВШЭ, 2026

# План презентации

1. Введение в задачу
2. Обзор литературы и постановка задачи
3. Датасет и методология
4. Baseline-модели
5. Продвинутые модели
6. Двухуровневая архитектура
7. Эксперименты и результаты
8. Выводы и дальнейшие перспективы

# Введение: задача up-sell рекомендаций

Проблема: как повысить средний чек покупателя, предлагая релевантные товары к уже выбранным?

Up-sell рекомендации - предложение дополнительных товаров, которые пользователь может добавить в корзину на основе уже выбранных позиций.

Особенности:

- Учет контекста текущей корзины
- Кросс-категориальные рекомендации
- Персонализация на основе истории покупок
- *Необходимость быстрого инференса в production

# Обзор литературы

| Модель | Подход | Преимущества | Недостатки |
|---|---|---|---|
| EASE (2019) | Простая и эффективная модель для коллаборативной фильтрации на основе линейных автоэнкодеров, оптимизированная для разреженных данных | Исключительная простота реализации и скорость работы, замкнутое решение без итеративной оптимизации, отличное качество для бейзлайна | Ограниченная выразительность из-за линейности, не учитывает временную динамику и последовательности, не использует дополнительные признаки товаров или пользователей. Чисто коллаборативный подход |
| Neural Pattern Associator (NPA) (2024) | Модель для задачи рекомендаций внутри корзины (within-basket recommendation), предсказывающая товары, которые пользователь может добавить к уже имеющимся в корзине | Специализированный подход для задачи дополнения корзины, учитывает контекст текущих товаров. Может выявлять сложные нелинейные зависимости между товарами. | Ограниченная применимость только к задаче within-basket рекомендаций, требует достаточного количества данных о совместных покупках. |
| Bi-directional Transformer Basket Recommendation (BTBR) (2023) | Модель на основе двунаправленных трансформеров для предсказания следующей корзины покупок на основе истории предыдущих корзин поль-зователя | Механизм внимания позволяет находить долгосрочные зависимости, двунаправленность улучшает понимание контекста. Трансформеры показывают хорошие результаты на последовательных данных. | Высокая вычислительная сложность трансформеров, требовательность к объему данных для обучения. Модель может быть избыточной для простых сценариев покупок. |
| Beacon (Basket Sequence Correlation Network) (2019) | Модель для предсказания следующей корзины, учитывающая корреляции Между последовательностями корзин (correlation-sensitive next basket recommendation). | Явное моделирование корреляций между товарами внутри корзин и между различными корзинами в последовательности. Использует внимание и свертки для захвата паттернов на разных уровнях (товар-товар, корзина-корзина). | Ограниченная гибкость архитектуры, может уступать более современным трансформер-подходам. Модель 2019 года, могут быть более свежие улучшения. |

# Постановка проблемы и мотивация

Недостатки существующих решений:

1. Простые методы (TopPopular, ассоциативные правила) - отсутствие персонализации, игнорирование индивидуальных предпочтений и контекста.

2. Коллаборативная фильтрация (EASE, iALS) - игнорируют временную динамику и порядок взаимодействий. Проблема холодного старта для новых пользователей/товаров.

3. Последовательные модели (RNN, Transformers) - требуют больших вычислительных мощностей, избыточность для простых паттернов.

4. Basket-специфичные модели (BTBR, NPA, Beacon) - ограниченная применимость, сложность адаптации к новым доменам.

<u>Цель работы</u>: разработать эффективную архитектуру для up-sell рекомендаций, сочетающую баланс между предсказаниями, вычислительной эффективностью и способностью к обобщению.

# **Датасет**: T-ECD (T-Bank E-Commerce Dataset)

В работе используется датасет T-ECD (T-Bank E-Commerce Dataset) – крупномасштабный датасет кросс-доменных данных российского ритейлера (Т-банк), включающий данные из Marketplace, Retail, Offers, Reviews, Payments доменов. Датасет содержит информацию о транзакциях, корзинах, товарах, брендах и отзывах пользователей.

- Публикация на Habr: https://habr.com/ru/companies/tbank/articles/950696/
- Датасет на Hugging Face: huggingface.co/datasets/t-tech/T-ECD

T-Технологии

**Сравнительная таблица открытых датасетов**

| Датасет | Пользователей | Айтемов | Взаимодействий |
|---|---|---|---|
| **T-ECD** | **44 млн** | **30 млн** | **135 млрд** |
| VK-LSVD | 10 млн | 20 млн | 40 млрд |
| Yambda-5B | 1 млн | 9 млн | 5 млрд |
| Criteo-1TB | - | - | 4 млрд |
| Amazon Reviews 2023 | 55 млн | 48 млн | 571 млн |

T-ECD — T-Tech E-commerce Cross-Domain Dataset

T-Технологии

**Статистики датасета**

Количественные характеристики доменов данных

| Домен | Уникальных айтемов | Интеракций |
|---|---|---|
| Marketplace | 28,6 млн | 2,2 млрд |
| Retail | 1,2 млн | 3,8 млрд |
| Offers | 87,7 тыс | 28,5 млрд |
| Payments (transactions) | - | 65,8 млрд |
| Payments (receipts) | 28,6 + 1,2 млн | 34,9 млрд |
| Reviews | - | 46,1 млн |
| **ВСЕГО** | 29,9 млн | 135,4 млрд |

# Метрики качества

Для оценки качества рекомендаций используются следующие метрики:

Метрики ранжирования:

- NDCG@100 - учитывает порядок рекомендаций (основная метрика)
- Recall@100 - покрытие релевантных товаров
- MRR (Mean Reciprocal Rank) - позиция первого релевантного товара

Метрики разнообразия:

- Catalog Coverage - доля каталога, покрытая рекомендациями
- Diversity - степень различия рекомендаций между пользователями (0 – одни и те же рекомендации, 1 –уникальные рекомендации)
- Serendipity - доля неожиданных и релевантных рекомендаций

Бизнес-метрики:

- avg_item_price - средняя цена рекомендованных товаров

# Комплексный бенчмаркинг моделей

В рамках исследования сравниваются различные подходы к задаче up-sell рекомендаций:

- Baseline-модели: TopPopular, TopPersonal, EASE, iALS, TIFU-KNN
- SOTA-модели: SASRec, BERT4Rec, Двухуровневая архитектура
- Basket-специфичные модели: NPA, BTBR, Beacon

Особое место в работе занимает разработка инновационной Generative Retrieval архитектуры, адаптированной для задачи up-sell рекомендаций на корзинах.

Для каждой модели рассчитываются метрики качества, что позволяет провести объективное сравнение подходов.

# Результаты baseline-моделей

| Модель | Что за модель | NDCG@100 | Recall@100 | MRR | Catalog Coverage | Diversity | Serendipity | Average price |
|---|---|---|---|---|---|---|---|---|
| TopPopular | Самые популярные товары в датасете | 0.082 | 0.078 | 0.129 | 0.003 | 0.000 | 0.042 | **-3.671** |
| TopPersonal | Самые товары для конкретного пользователя | **0.375** | **0.228** | **0.401** | **0.996** | **0.998** | 0.000 | -3.860 |
| EASE | Линейный автоэнкодер | 0.055 | 0.056 | 0.118 | 0.365 | 0.991 | 0.039 | -3.889 |
| iALS | Матричная факторизация для implicit feedback | 0.060 | 0.067 | 0.120 | 0.143 | 0.977 | **0.042** | -3.814 |
| TIFU-KNN | KNN-подход с учетом временных и частотных характеристик | 0.148 | 0.125 | 0.185 | 0.785 | 0.996 | 0.020 | -3.812 |

**Вывод**: TopPersonal показывает лучшие результаты по всем ключевым метрикам благодаря персонализированным рекомендациям на основе истории пользователя. TopPopular рекомендует самые дорогие товары, но с низким качеством ранжирования.

# Результаты SOTA-моделей

| Модель | Что за модель | NDCG@100 | Recall@100 | MRR | Catalog Coverage | Diversity | Serendipity |
|---|---|---|---|---|---|---|---|
| SASRec | Трансформер с self-attention для захвата последовательных зависимостей | 0.163 | 0.127 | 0.192 | 0.761 | 0.996 | 0.036 |
| BERT4Rec | Bidirectional encoder с маскированием элементов | **0.289** | 0.187 | **0.329** | 0.795 | 0.996 | 0.030 |
| LightGCN | Graph Convolutional Network на графе user-item взаимодействий | 0.219 | 0.196 | 0.251 | 0.992 | 0.997 | 0.027 |
| LightFM | Гибридный подход с использованием user- и item- features | 0.231 | **0.217** | 0.227 | 0.952 | 0.997 | 0.017 |
| BiVAE | Вариационный автоэнкодер для коллаборативной фильтрации | 0.162 | 0.144 | 0.232 | 0.697 | 0.995 | 0.035 |
| BPR | Bayesian Personalized Ranking | 0.203 | 0.187 | 0.238 | 0.697 | 0.995 | 0.037 |

**Вывод**: BERT4Rec показывает лучшее качество (NDCG@100=0.289) благодаря bidirectional контексту, но все еще уступает модели TopPersonal (0.375).

# Двухуровневая архитектура

**Мотивация**: преодоление ограничений отдельных моделей через ансамблирование

**Архитектура**:

1. Candidate Generation
   - Быстрая генерация кандидатов из всего каталога (~100-500 товаров)
   - Ансамбль из 9 моделей: TopPopular, TopPersonal, EASE, iALS, TIFU-KNN, BERT4Rec, BiVAE, BPR, LightFM, SASRec

2. Ranking
   - Точное переранжирование отобранных кандидатов
   - Два подхода: CatBoost Ranker и Reciprocal Rank Fusion (RRF)

# Feature Engineering

**1. user features**:

- Socdem_cluster
- Region
- Дней с последнего заказа
- Дней с первого заказа
- Lifetime (days)
- Основная операционная система
- Количество заказов
- Средний чек
- Суммарная выручка
- Основной источник покупок (каталог / поиск / ..)
- Кол-во уник брендов в истории
- Кол-во уник категорий в истории
- Кол-во уник товаров в истории
- Вариативность цен (std)

**2. item features**:

- Brand embedding
- Item_category
- Item_subcategory
- Item_price
- Item_embedding
- Кол-во уник пользователей за все время
- Общее кол-во просмотров, кликов, добавлений, CTR
- Популярность по окнам (3, 7, 30 дней)
- Относительная цена в категории
- Отклонение от средней цены категории

**3. user-brand features**:

- Количество заказов этого бренда
- Доля бренда в общих покупках юзера, его ранг
- Дней с первой покупки бренда
- Дней с последней покупки бренда
- Средний, мин, макс чек бренда

**4. user-category features**:

- Количество покупок в категории
- Доля категории в покупках юзера
- Средний чек в категории
- Дней с последней покупки в категории

**5. user-item features**:

- Кол-во ивентов
- Кол-во кликов, просмотров, добавлений в корзину
- CTR (из клика в корзину, из просмотра в корзину)
- Основной источник покупок (каталог / поиск / ..)
- Дней с последней покупки
- Дней с первой покупки

**6. brand features**:

- Средний, мин, макс рейтинг из reviews
- Усредненный эмбеддинг из reviews

# Reciprocal Rank Fusion (RRF)

Данный метод присваивает каждому товару общий балл как сумму вкладов от каждого списка рекомендаций, где вклад обратно пропорционален позиции товара в списке (чем выше товар, тем больше вклад). В итоге RRF повышает элементы, которые стабильно попадают в топ у разных моделей, и менее чувствителен к различиям шкал оценок между моделями.

Параметр *k* используется для сглаживания эффекта очень высоких рангов и уменьшения вклада результатов с низкими рангами.

Стандартный RFF объединяет ранги моделей через формулу:

$$\mathrm{Score(item)} = \sum \frac{1}{\mathrm{k} + \mathrm{rank_model(item)}}$$

Взвешенный RRF каждой модели присваиваются свои веса:

$$\mathrm{Score(item)} = \sum \frac{\mathrm{model_weight}}{\mathrm{k} + \mathrm{rank_model(item)}}$$

# Результаты двухуровневой архитектуры

| Подход | NDCG@100 | Recall@100 | MRR | Catalog Coverage | Diversity | Serendipity |
|---|---|---|---|---|---|---|
| TopPersonal (лучший baseline) | 0.375 | 0.228 | 0.401 | 0.996 | 0.998 | 0.000 |
| CatBoost Ranker | 0.320 | 0.229 | 0.343 | 0.995 | 0.997 | 0.014 |
| RRF (standard) | 0.316 | 0.262 | 0.308 | 0.921 | 0.997 | **0.035** |
| RRF (weighted) | **0.378** | **0.273** | 0.383 | **0.970** | 0.997 | 0.021 |

**Улучшение**: RRF (weighted) дал +0.8% NDCG@100 относительно лучшего baseline (TopPersonal)

**Преимущества**:

- Взвешенный RRF использует веса равные NDCG@100 каждой модели на валидации
- Повышение Recall@100 с 0.228 до 0.273 (+20%)
- Появление Serendipity (0.021) vs 0.000 у TopPersonal
- Сохранение высоких значений Catalog Coverage и Diversity

# Анализ результатов и инсайты

Ключевые наблюдения:

1. TopPersonal - сильный baseline
   - Простая эвристика “рекомендуй то, что пользователь покупал чаще всего” дает NDCG@100=0.375
   - Объяснение: высокая повторяемость покупок в retail-домене
2. Sequential модели (BERT4Rec, SASRec) из коробки уступают TopPersonal
   - BERT4Rec: NDCG@100=0.289 (на 23% хуже)
   - Причина: в ритейле часто нет строгих последовательных паттернов - пользователь просто возвращается к любимым товарам.
3. Weighted RRF побеждает все отдельные модели
   - Комбинация 9 моделей с правильными весами дает +0.7% к TopPersonal
   - Ключевой инсайт: веса равные NDCG@100 каждой модели на валидации
4. CatBoost не смог обыграть простой RRF
   - Несмотря на 72 признака, CatBoost дает NDCG@100=0.320
   - Переобучение на ранги TopPersonal (importance=56%)

# Ограничения и Future Work

Ограничения текущего подхода:

- Weighted RRF требует предварительной валидации для определения весов, также требуется обучить все базовые модели по-отдельности
- CatBoost показал переобучение на ранги TopPersonal
- Sequential модели не оптимальны для данной задачи
- Есть проблема холодного старта новых пользователей/товаров

Направления развития:

1. Бенчмаркинг Basket-специфичных моделей (NPA, Beacon)
2. Реализция собственной архитектуры, ее бенчмаркинг, две ключевые идеи:
   - Embedding-based Retrieval
   - Generative Retrieval

# Спасибо за внимание!

Контакты:

Email: daalliapin@edu.hse.ru

Tg: @danila_lyapin

GitHub: github.com/Lak1n26/hse-masters-thesis-2026

# Приложение 1: метрики качества

NDCG@k (Normalized Discounted Cumulative Gain)

$$\text{NDCG@k} = \frac{\text{DCG@k}}{\text{IDCG@k}}$$

$$\text{DCG@k} = \sum_{i=1}^{k} \frac{rel_i}{\log_2(i+1)}$$

где $rel_i$ — релевантность i-го элемента (1 если релевантен, 0 иначе)

Precision@k

$$\text{Precision@k} = \frac{|\text{relevant items in top}-\text{k}|}{k}$$

Recall@k

$$\text{Recall@k} = \frac{|\text{relevant items in top}-\text{k}|}{|\text{all relevant items}|}$$

# Приложение 2: CatBoost Feature Importance

Top-10 наиболее важных признаков

| Feature | Importance | Type |
|---|---|---|
| rank_toppersonal | 56.25 | Candidate score |
| rank_tifuknn | 21.88 | Candidate score |
| user_items | 7.90 | User feature |
| rank_lightfm | 6.44 | Candidate score |
| rank_bpr | 3.54 | Candidate score |
| user_id | 1.12 | User feature |
| rank_ials | 0.97 | Candidate score |
| user_item_clicked_total | 0.82 | User-item feature |
| user_orders | 0.41 | User feature |
| user_item_lifetime | 0.33 | User-item feature |

**Вывод**: ранги персонализированных моделей (TopPersonal, TIFU-KNN) вносят наибольший вклад в финальное ранжирование.